

## Checkpoint 4 - Grupo 26

### Introducción

Empezamos tomando los datasets que obtuvimos en los checkpoints anteriores, en donde los separamos en 2 conjuntos, uno para el entrenamiento y el otro para testear. Para el entrenamiento, tomamos un 70%, y para el test, un 30%.

Cada integrante del grupo decidió entrenar un modelo y evaluar su performance. Para algunos modelos, decidimos usar datasets transformados, ya sea normalizados o escalados.

Para elegir el mejor modelo, nos basamos en las predicciones que obtuvimos usando los conjuntos de test y analizando sus métricas.

### Construcción del modelo

Detallar como mínimo los siguientes puntos para el “mejor” modelo obtenido:

Tomaremos como parámetro de “mejor” modelo, al que haya obtenido el más alto puntaje de F1. Estamos hablando del modelo 2.

- ¿Cuál fue la arquitectura escogida? Se escogió una arquitectura de 3 capas densas.
  - Capa entrada
    - 128 neuronas de entrada
    - Función de activación: ReLU
    - Tipo de conexión: Al ser densa, está completamente conectada a las otras capas
  - Capas ocultas
    - 64 y 32 neuronas por capa respectivamente
    - Función de activación: ReLU
    - Tipo de conexión: Al ser densa, está completamente conectada a las otras capas
  - Capa de salida
    - 1 neurona
    - Función de activación: Sigmoid

- ¿Qué hiperparametros se optimizaron? Se optimizaron la learning\_rate y la función de pérdida binary\_crossentropy
- ¿Qué optimizador se utilizó? Se utilizó el optimizador Adam con un learning rate de 0.001
- ¿Se utilizó alguna técnica de regularización? ¿Cuál? Se utilizó la técnica de dropout para regularizar el modelo, con una tasa del 20%.
- ¿Cuántos ciclos de entrenamiento utilizó? Se utilizaron 50 ciclos de entrenamiento

## Cuadro de Resultados

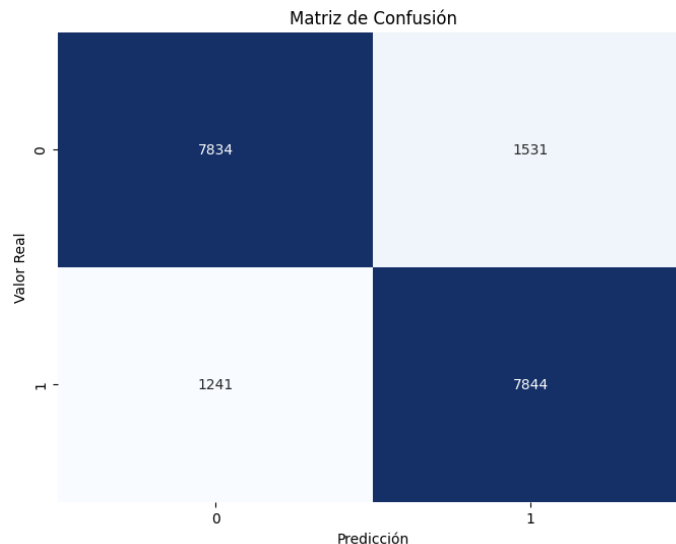
Modelo	F1-Test	Precision Test	Recall Test	Accuracy	Kaggle
Modelo 1	0.83972	0.84501	0.83450	0.83609	0.74430
Modelo 2	0.84983	0.83669	0.86340	0.84975	0.71547
Modelo 3	0.84177	0.83562	0.84801	0.84037	0,68869

- Modelo 1: Es una red neuronal para clasificación, que consta de una capa de entrada, capas ocultas con activación relu y una capa de salida con activación sigmoid.
- Modelo 2:
  - Capa de entrada:  
1 capa de entrada
  - Capas ocultas:  
Primera capa oculta:  
Cantidad de neuronas: 128  
Función de activación: ReLU  
Capa de dropout:  
Ratio de dropout: 20%  
Segunda capa oculta:  
Cantidad de neuronas: 64  
Función de activación: ReLU  
Capa de dropout:  
Cantidad de neuronas: 32

Función de activación: ReLU  
Tercera capa oculta:  
Ratio de dropout: 20%  
-Capa de salida:  
1 Neurona de salida  
Función de activación: Sigmoid

- Modelo 3: Es una red neuronal, para problemas de clasificación binaria, que consta de una capa de entrada, 2 ocultas y una de salida. La capa de entrada tiene 256 neuronas, y las dos ocultas 128 y 64 respectivamente, junto a dos capas de dropout del 30%. La capa de salida posee una sola neurona ya que es un problema de clasificación binaria. Se utilizó la función de activación de tangente hiperbólica para todas las capas excepto para la de salida, que se usó Sigmoid.

## Matriz de Confusion



En esta matriz se puede apreciar un muy correcto número de verdaderos positivos, con una tendencia del 86.34% de los casos positivos bien predichos. También una correcta predicción del 83.67% de los casos negativos

## Tareas Realizadas

Integrante	Tarea
Garcia, Nicolas	Armado de reporte Entrenamiento modelo 3
Vallcorba, Agustin	Armado de reporte Entrenamiento modelo 2
Carbajal Robles, Kevin Emir	Armado de reporte Entrenamiento modelo 1